


EAI LABs Reports - Lab5

Testing on Public Gradio Interface (10%)


On Macbook

Deer



FP32 inference time: 19.18 ms
INT8 inference time: 17.09 ms
Speedup (FP32/INT8): 1.12×

Cat



FP32 inference time: 18.24 ms
INT8 inference time: 16.74 ms
Speedup (FP32/INT8): 1.09×

Car

CIFAR-10 Image Classifier: FP32 vs INT8

Upload an image to compare FP32 and INT8 model predictions

image



Clear

Submit

FP32 Top-3

car

car

cat

deer

82%

8%

5%

INT8 Top-3

car

car

cat

deer

82%

9%

5%

Performance Summary

FP32 inference time: 18.08 ms

INT8 inference time: 16.02 ms

Flag

FP32 inference time: 18.08 ms
INT8 inference time: 16.02 ms
Speedup (FP32/INT8): 1.13×

Plane

image



FP32 Top-3

deer

deer

bird

plane

97%

2%

1%

INT8 Top-3

deer

deer

bird

cat

96%

2%

1%

Performance Summary


FP32 inference time: 17.62 ms

INT8 inference time: 16.26 ms

Flag

FP32 inference time: 16.88 ms
INT8 inference time: 16.26 ms
Speedup (FP32/INT8): 1.04×

Plane (Resized)



INT8 Top-3

deer

deer

98%

cat

2%

bird

0%

Performance Summary

FP32 inference time: 29.59 ms


INT8 inference time: 31.61 ms

Flag

FP32 inference time: 29.59 ms
INT8 inference time: 31.61 ms
Speedup (FP32/INT8): 0.94x

On iPhone

Deer



Submit

FP32 Top-3

deer

deer	100%
bird	0%
cat	0%

INT8 Top-3

deer

deer	100%
bird	0%
cat	0%

e35052a1e8ccd3d802.gradio.live

Performance Summary

FP32 inference time: 29.62 ms
INT8 inference time: 27.47 ms
Speedup (FP32/INT8): 1.08x

Cat

21:35

Image

100



Share

Fullscreen

Copy

Clear

Submit

FP32 Top-3


cat

cat

100%


bird

0%



FP32 inference time: 17.53 ms
INT8 inference time: 17.12 ms
Speedup (FP32/INT8): 1.02x

Car






Clear

Submit


FP32 Top-3

car



INT8 Top-3

car



deer

e35052a1e8ccd3d802.gradio.live

5%

FP32 inference time: 19.33 ms
INT8 inference time: 17.39 ms
Speedup (FP32/INT8): 1.11×

Plane

21:35






Clear


Submit

 FP32 Top-3



FP32 inference time: 17.61 ms
INT8 inference time: 16.29 ms
Speedup (FP32/INT8): 1.08x

Plane (Resized)





Clear

Submit

FP32 Top-3


deer



INT8 Top-3

deer





```
FP32 inference time: 17.05 ms  
INT8 inference time: 15.60 ms  
Speedup (FP32/INT8): 1.09x
```

Analysis of Inference Results

在測試過程中觀察到圖片類型和 preprocessing 對 prediction results 的影響。使用真實照片進行測試時，deer 和 cat 的圖片即使保持原始解析度不經縮放，predictions 仍然正確。相對地，car 和部分 plane 圖片在不同解析度下表現不一。

測試初期使用了 32x32 的 icon 圖示作為輸入，三張 plane icon 的 predictions 全部錯誤，分別被預測為 cat 和 frog。這些 icon 雖然符合 model input 的尺寸要求，但預測失敗。後續改用真實照片後，deer, cat, car 三個類別都獲得正確的 predictions，而 plane 類別則出現部分成功、部分失敗的情況。

最終採用的測試圖片包含 deer, cat, car, plane 四個類別的真實照片。從 performance summary 可以看到，FP32 和 INT8 模型在每個測試案例上產生的 top-3 predictions 完全一致，顯示 quantization 沒有改變模型的 classification behavior。

Difference between FP32 and INT8 (10%)

Implementation Design

在 Gradio interface 的 implementation 中，核心函數是 `compare_fp32_int8`，負責同時執行 FP32 和 INT8 模型的 inference 並比較結果：

```
def compare_fp32_int8(image: Image.Image):  
    if image is None:  
        return {}, {}, "Please Upload Your Image."  
    if sess_fp32 is None:  
        return {}, {}, (_fp32_err or "The FP32 model has not been  
provided, so a comparison cannot be made.")  
  
    x = preprocess(image)
```

```

t0 = time.time()
logits_fp32 = sess_fp32.run([out_fp32], {in_fp32: x})[0]
fp32_ms = (time.time() - t0) * 1000

t0 = time.time()
logits_int8 = sess_int8.run([out_int8], {in_int8: x})[0]
int8_ms = (time.time() - t0) * 1000

p_fp32 = softmax_np(logits_fp32[0])
p_int8 = softmax_np(logits_int8[0])

def top3_map(p):
    idx = np.argpartition(p, -3)[-3:]
    idx = idx[np.argsort(p[idx])[:-1]]
    return {LABELS[i]: float(p[i]) for i in idx}

top3_fp32 = top3_map(p_fp32)
top3_int8 = top3_map(p_int8)

summary = (
    f"FP32 inference time: {fp32_ms:.2f} ms\n"
    f"INT8 inference time: {int8_ms:.2f} ms\n"
    f"Speedup (FP32/INT8): {(fp32_ms / max(int8_ms, 1e-9)):.2f}x"
)
return top3_fp32, top3_int8, summary

```

函數首先對輸入圖片執行 `preprocess`，將 PIL Image 轉換為 32×32 的 normalized tensor。接著分別執行兩個模型的 inference，使用 `time.time()` 測量各自的 execution time 並轉換為毫秒單位。

執行完成後，將兩個模型的 logits 輸出經過 `softmax_np` 轉換為 probability distribution，然後使用 `top3_map` 提取機率最高的三個類別。這個 nested function 使用 `np.argpartition` 找出前三大值的 index，再用 `argsort` 排序，最後轉換為 dictionary 格式。

最終函數回傳三個值：FP32 的 top-3 predictions、INT8 的 top-3 predictions，以及包含兩個模型 inference time 與 speedup 比較的 summary text。這個設計讓 Gradio interface 能同時顯示 accuracy 與 performance 的差異。

Performance Comparison and Observations

Macbook 平台測試結果：

Image	FP32 (ms)	INT8 (ms)	Speedup
Deer	19.18	17.09	1.12×
Cat	18.24	16.74	1.09×
Car	18.08	16.02	1.13×
Plane	16.88	16.26	1.04×
Plane (Resized)	29.59	31.61	0.94×

iPhone 平台測試結果：

Image	FP32 (ms)	INT8 (ms)	Speedup
Deer	29.62	27.47	1.08×
Cat	17.53	17.12	1.02×
Car	19.33	17.39	1.11×
Plane	17.61	16.29	1.08×
Plane (Resized)	17.05	15.60	1.09×

從測試數據觀察到 INT8 quantization 在大多數案例中提升了 inference speed。Macbook 上的 speedup 範圍為 1.04× 到 1.13×（排除異常值），iPhone 上則為 1.02× 到 1.11×。Macbook 上的 plane resized 案例出現 0.94× 的結果，INT8 反而比 FP32 慢。

兩個平台的 speedup pattern 相近，但 absolute inference time 有明顯差異。FP32 和 INT8 模型在所有測試案例上產生完全相同的 top-3 predictions，顯示 quantization 保持了模型的 classification capability。

Reflections and Suggestions for This Lab (5%)

本次 Lab 成功展示了從 PyTorch model 到 web deployment 的完整流程，涵蓋 ONNX conversion、INT8 quantization 以及 Gradio interface 的建置。相較於 Lab3 和 Lab4 著重於特定技術的深入探討，Lab5 更注重實際 deployment 的整合應用，讓我們了解如何將訓練好的 model 部署為可用的 web service。

在實作過程中，感覺有幾點可以進一步加強。首先，測試圖片的選擇標準感覺其實不太準確？。講義中有提到「圖片要盡量找跟 model input 大小相近的」，但實際測試發現圖片類型（真實照片 vs 圖示）對 prediction accuracy 的影響更為關鍵。若能提供 CIFAR-10 test set 的 subset 作為 benchmark，或是明確說明適合的圖片特徵，感覺會更有方向？

然後 Gradio public link 的運作機制值得在講義中補充說明。Public link 會在 Colab session 結束時失效，初次使用時可能需要一些時間理解這個行為。若能在講義中加入 troubleshooting section，說明如何重新啟動 server 或使用 local deployment，會更有幫助。

接著在 quantization 的部分感覺有點摸不著頭緒。我通過實驗觀察到 speedup 範圍為 1.02× 到 1.13×，對於 ResNet18 這樣的輕量級 model 而言，quantization 帶來的效益相對有限。可能要說明一下 quantization 在本次 Lab 中想要學生實作的方向或是意義。